

Αλγοριθμική Επιστήμη Δεδομένων

1η Σειρά Ασκήσεων

Ακαδημαϊκό έτος 2023-24

Άσκηση 1

α) Θέτουμε $x = 0$ και $y = m$ (το τελευταίο υφίσταται διότι $U = [m^k]$, $k \geq 2$).
Τότε:

- $h_{\alpha,\beta}(x = 0) = (\alpha \cdot 0 + \beta) \bmod m \equiv \beta \bmod m$
- $h_{\alpha,\beta}(y = m) = (\alpha \cdot m + \beta) \bmod m \equiv (\alpha \cdot m) \bmod m + \beta \bmod m \equiv \beta \bmod m$

Όλες οι $h_{\alpha,\beta}$ της \mathcal{H} για $x = 0$ και $y = m$ δίνουν την ίδια τιμή άρα βρήκαμε $x \neq y$ τ.ω. $h_{\alpha,\beta}(x) = h_{\alpha,\beta}(y) \forall h_{\alpha,\beta} \in \mathcal{H}$, οπότε $\mathbb{P}_{h \in \mathcal{H}}[h(x) = h(y)] = 1$ και άρα δεν ισχύει η ιδιότητα της καθολικότητας.

β) Θέτουμε την οικογένεια συναρτήσεων $\mathcal{H} = \{h_{\alpha,\beta} : \alpha \in [p] \setminus \{0\}, \beta \in [p]\}$ όπου

$$h_{\alpha,\beta}(x) = [(\alpha x + \beta) \bmod p] \bmod m, \quad x \in \mathcal{U} = [p] \quad (1)$$

Θα δείξουμε ότι η \mathcal{H} είναι καθολική.

Για $x \neq y$ θα υπολογίσουμε το πλήθος των $h_{\alpha,\beta} \in \mathcal{H}$ ώστε $h_{\alpha,\beta}(x) = h_{\alpha,\beta}(y)$.

$$h_{\alpha,\beta}(x) = h_{\alpha,\beta}(y) \implies$$

$$[(\alpha x + \beta) \bmod p] \bmod m \equiv [(\alpha y + \beta) \bmod p] \bmod m \implies$$

$$[(\alpha x + \beta) \pmod p] \equiv [(\alpha y + \beta) \pmod p] + im \text{ με } i \in \left[-\left\lfloor \frac{p-1}{m} \right\rfloor, \left\lfloor \frac{p-1}{m} \right\rfloor\right] \implies$$

$\alpha(x - y) \equiv_p im$ και ο p είναι πρώτος άρα αν $x \neq 0$ τότε υπάρχει ο αντίστροφός

$$\alpha \equiv_p im(x - y)^{-1} (*)$$

Υποθέτουμε Χ.Β.Τ.Γ. ότι $x > y \Rightarrow x - y > 0$ άρα υπάρχει ο $(x - y)^{-1} \not\equiv_p 0$ διότι p είναι πρώτος.

Πρέπει να ισχύει ότι $i > 0$ άρα υπάρχουν το πολύ $\left\lfloor \frac{p-1}{m} \right\rfloor$ τιμές του i για τις οποίες θα ισχύει η (*). Εφόσον λοιπόν $\alpha \in [p] \setminus \{0\}$, από τις $p - 1$ επιλογές της τιμής του α , μόνο για τις $\left\lfloor \frac{p-1}{m} \right\rfloor$ το πλήθος θα ισχύει ότι $h_{\alpha,\beta}(x) = h_{\alpha,\beta}(y)$ (οι διάφορες τιμές του β δεν επηρεάζουν το αποτέλεσμα). Οπότε

$$\mathbb{P}_{h \in \mathcal{H}}[h_{\alpha,\beta}(x) = h_{\alpha,\beta}(y)] = \frac{\left\lfloor \frac{p-1}{m} \right\rfloor}{p-1} \leq \frac{p-1}{m(p-1)} = \frac{1}{m}$$

Δείξαμε ότι μια οικογένεια συναρτήσεων είναι καθολική για το $\mathcal{U} = [p]$ οπότε για κάθε $\mathcal{U}' \subseteq \mathcal{U}$ αν $x \neq y$ και $x, y \in \mathcal{U}' \Rightarrow x, y \in \mathcal{U} \Rightarrow$ υπάρχουν το πολύ $\frac{|\mathcal{H}|}{m}$ το πλήθος $h_{\alpha,\beta} \in \mathcal{H} : h_{\alpha,\beta}(x) = h_{\alpha,\beta}(y)$. Άρα, για κάθε υποσύνολο του \mathcal{U} ισχύει η ιδιότητα της καθολικότητας, συνεπώς και για το $\mathcal{U}'' = [m^k]$, $k \geq 2$ με $m_k < p$ διότι τότε $[m^k] \subseteq [p]$.

γ) Με βάση τα παραπάνω η ιδιότητα της καθολικότητας ισχύει αν $\mathcal{U} = [p]$.

Άσκηση 2

α) Δεδομένου ότι η ανοιχτή διευθυνσιοδότηση δουλεύει με γραμμική διερεύνηση, ο χρόνος που απαιτείται για την εισαγωγή του i -οστού στοιχείου είναι ο ίδιος με τον χρόνο που απαιτείται για την επιτυχή αναζήτησή του. Συνεπώς και ο μέσος χρόνος διεκπεραίωσης των δύο διαδικασιών είναι ίδιος.

β) Έστω Ω_i το πλήθος των βημάτων επιτυχούς αναζήτησης/εισαγωγής (είναι ίσα από το (α)) του i -οστού στοιχείου. Θα εξετάσουμε το ενδεχόμενο $\Omega_i \geq k$. Προκειμένου να χρειαστούν k βήματα για να εισάγουμε ένα στοιχείο, προϋποτίθεται η θέση h_i (όπου h συνάρτηση κατακερματισμού) καθώς και οι επόμενες $k - 1$ θέσεις να είναι κατειλημμένες. Από την υπόθεση της ομοιομορφίας αυτό

έχει πιθανότητα να συμβεί

$$\mathbb{P}(\Omega \geq k) = \frac{i-1}{m} \cdot \frac{i-2}{m} \cdot \dots \cdot \frac{i-k}{m-k+1} \leq \alpha_{i-1}^k$$

όπου $\alpha_{i-1} = \frac{i-1}{m}$. Εμάς μας ενδιαφέρει να φράξουμε τη μέση τιμή της $\Omega = \frac{\Omega_1 + \Omega_2 + \dots + \Omega_n}{n}$. Έχουμε

$$\begin{aligned}
\mathbb{E}[\Omega] &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\Omega_i] \\
&= \frac{1}{n} \sum_{i=1}^n \left(\sum_{k=1}^{\infty} \mathbb{P}[\Omega_i \leq k] \right) \\
&\leq \frac{1}{n} \sum_{i=1}^n \left(\sum_{k=1}^{\infty} \alpha_{i-1}^k \right) \\
&\leq \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{1 - \alpha_{i-1}} \right) \\
&= \frac{1}{n} \sum_{i=1}^n \frac{m}{m - (i - 1)} \\
&= \frac{m}{n} \left(\frac{1}{m - n + 1} + \dots + \frac{1}{m} \right) \\
&\leq \frac{m}{n} \int_{m-n}^m \frac{1}{x} dx \\
&= \frac{m}{n} \cdot \ln \frac{m}{m - n} \\
&= \frac{1}{\alpha} \cdot \ln \frac{1}{1 - \alpha},
\end{aligned} \tag{2}$$

δηλαδή το ζητούμενο.

Άσκηση 3

Άσκηση 6.3.1 από το βιβλίο *MMDS*:

Μας δίνεται *support threshold*=4 και *hash table* με 11 *buckets*.

α) Το *support* κάθε *itemset* ισούται με τον αριθμό των φορών που εμφανίζεται ως υποσύνολο σε κάθε ένα από τα *baskets*.

Item	Support
1	4
2	6
3	8
4	8
5	6
6	4

Table 1: Support of every item in baskets

Itemset	Support
{1,2}	2
{1,3}	3
{1,4}	2
{1,5}	1
{1,6}	0
{2,3}	3
{2,4}	4
{2,5}	2
{2,6}	1
{3,4}	4
{3,5}	4
{3,6}	2
{4,5}	3
{4,6}	3
{5,6}	2

Table 2: Support of every itemset in baskets

β) Κάθε ζεύγος i, j κατακερματίζεται στο καλάθι με τιμή $(i \times j) \bmod 11$.

Itemset	Bucket
{1,2}	2
{1,3}	3
{1,4}	4
{1,5}	5
{1,6}	6
{2,3}	6
{2,4}	8
{2,5}	10
{2,6}	1
{3,4}	1
{3,5}	4
{3,6}	7
{4,5}	9
{4,6}	2
{5,6}	8

Table 3: Buckets of all the Pairs.

γ) Υπολογίζουμε το *support* του κάθε *bucket* αθροίζοντας τα *supports* των δυ-
συνόλων που αντιστοιχίζονται σε αυτό το *bucket*. Ορίζουμε *frequent buckets*
αυτά τα οποία έχουν $support \geq 4$.

Bucket	Support
0	0
1	5
2	5
3	3
4	6
5	1
6	3
7	2
8	6
9	3
10	2

Table 4: Supports for each bucket.

Συμπεραίνουμε ότι τα *frequent buckets* είναι τα 1, 2, 4 και 8.

δ) Στην δεύτερη φάση του *PCY* θα περάσουν τα 2,6 με 3,4 για το *bucket* 1, τα 1,2 με 4,6 για το *bucket* 2, τα 1,4 με 3,5 για το *bucket* 4 και τα 2,4 με 3,4 για το *bucket* 8.

Άσκηση 6.4.2 από το βιβλίο *MMDS*:

Άσκηση 4

α) Ο αλγόριθμος *A-priori* έχει ως στόχο να εντοπίσει τα πιο *frequent itemsets* τα οποία καθορίζονται από ένα κατώφλι s (αλλιώς *support*). Ένα *itemset* χαρακτηρίζεται *frequent* εάν συναντάται σε τουλάχιστον s το πλήθος *market baskets*. Δουλεύει αποκλείοντας τα περισσότερα πολυπληθή υποψήφια σύνολα εξετάζο-

ντας πρώτα αν τα υποσύνολά τους ξεπερνούν το κατώφλι, λαμβάνοντας υπόψιν ότι ένα μεγάλο σύνολο δεν μπορεί να είναι *frequent* αν δεν είναι πρώτα όλα τα υποσύνολά του (αντι-μονοτονικότητα). Διασφαλίζεται έτσι η ορθότητα του αλγορίθμου. Παρόλα αυτά είναι χρονοβόρος, καθώς το πέρασμα στη βάση δεδομένων μπορεί να συμβεί κ φορές, όσο και ο μεγαλύτερος από τους πληθάριθμους των *frequent itemsets*.

β) Η χρονική πολυπλοκότητα του Αλγορίθμου *A – priori* είναι πολυωνυμική ($\mathcal{O}(m \cdot n^2)$) ως προς την έξοδο, όπου m ο αριθμός των συχνών *itemsets* και n ο συνολικός αριθμός των *items*. Όπως αναφέρουμε και στο ερώτημα (α) ο χρόνος εκτέλεσης ισούται με τον μεγαλύτερο από τους πληθάριθμους των *frequent itemsets*, όπου αυτός ο αριθμός είναι συνήθως πολύ μικρότερος από το πλήθος των *items*.

γ) Ο αλγόριθμος ΦΠ-Γρωτη βασίζεται σε μια δομή που ονομάζεται ΦΠ-τρεε. Η διαφορά του με τον Α-πριορι είναι πως δεν προσπαθεί να παράγει υποψήφια ιτεμσετς αλλά να ανακαλύψει συσχετίσεις. Υπάρχει όμως ομοιότητα στην πολυπλοκότητα εξόδου μεταξύ των δύο αλγορίθμων, η οποία είναι επίσης πολυωνυμική.

δ) Το *support threshold* $s = 5$. Καταγράφουμε για αρχή όλα τα μονοσύνολα και το *support* τους στον παρακάτω πίνακα, δηλαδή το πλήθος των συνόλων στα οποία είναι υποσύνολα.

|

Item	Support
{a}	11
{b}	13
{c}	11
{d}	14

Εφόσον όλα τους έχουν *support* ≥ 5 θα προχωρήσουν όλα στο επόμενο βήμα στο οποίο θα πάρουμε όλα τα πιθανά δυσυνόλα και θα μετρήσουμε το *support* τους.

|

Item	Support
{a, b}	4
{a, c}	7
{a, d}	8
{b, c}	6
{b, d}	8
{c, d}	6


Το $\{a, b\}$ έχει $support = 4 < s$ οπότε δεν θα το συμπεριλάβουμε στις υπόλοιπες αναζητήσεις.

Item	Support
{a, c, d}	4
{b, c, d}	3

Παρατηρούμε ότι κανένα από τα σύνολα με τρία *items* δεν είναι *frequent*.
ε)

Άσκηση 5

Άσκηση 7.2.2 από το βιβλίο *MMDS*:



α) Εάν ορίζουμε ως απόσταση των δύο *clusters* την μικρότερη απόσταση δύο οποιωνδήποτε σημείων αυτών των δύο *clusters*, τότε η συσταδοποίηση θα άλλαζε ως εξής:

Τα κοντινότερα ζευγάρια σημείων θα είναι τα (10, 5) με (11, 4) ή τα (11, 4) με (12, 3) και τα δύο με απόσταση $\sqrt{2}$. Συγχωνεύουμε αυθαίρετα τις (11, 4) και (12, 3). Το (10, 5) απέχει από το (11, 4) πάλι την μικρότερη απόσταση ($\sqrt{2}$), οπότε δημιουργείται το *cluster* $\{(10, 5), (11, 4), (12, 3)\}$.

Τώρα τα κοντινότερα *clusters* είναι η $\{(4, 8)\}$ με την $\{(4, 10)\}$ και η $\{(4, 8)\}$ με την $\{(6, 8)\}$ έχοντας απόσταση 2. Άρα καταλήγουμε στον σχηματισμό του $\{(4, 8), (4, 10), (6, 8)\}$.

Τώρα υπάρχουν πολλά ζευγάρια με απόσταση $\sqrt{5}$:

- (2, 2) με (3, 4)
- (9, 3) με (10, 5) $\in \{(10, 5), (11, 4), (12, 3)\}$
- (12, 6) με (11, 4) $\in \{(10, 5), (11, 4), (12, 3)\}$
- (7, 12) με (6, 8) $\in \{(4, 8), (4, 10), (6, 8)\}$

Έτσι προκύπτουν τα εξής *clusters*:

- $\{(2, 2), (3, 4)\}$
- $\{(10, 5), (11, 4), (12, 3), (9, 3), (12, 6)\}$
- $\{(6, 8), (7, 10), (4, 8), (4, 10)\}$

Τέλος έχουμε απόσταση $\sqrt{8}$ μεταξύ των

- (5, 2) με (3, 4) $\in \{(2, 2), (3, 4)\}$

Καταλήγουμε στα *clusters*:

- $\{(2, 2), (3, 4), (5, 2)\}$
- $\{(6, 8), (7, 10), (4, 8), (4, 10)\}$
- $\{(10, 5), (11, 4), (12, 3), (9, 3), (12, 6)\}$

β) Θεωρώντας τώρα ως απόσταση τον μέσο όλων των αποστάσεων μεταξύ των σημείων του ενός με τα σημεία του άλλου *cluster* έχουμε ότι τα κοντινότερα ζευγάρια σημείων είναι τα (10, 5) με (11, 4) και (11, 4) με (12, 3) με απόσταση $\sqrt{2}$. Συγχωνεύουμε αυθαίρετα ένα ζευγάρι και παίρνουμε το *cluster* {(11, 4), (12, 3)}. Η αμέσως επόμενη μικρότερη απόσταση είναι αυτή των (4, 8) με (4, 10) και των (4, 8) με (6, 8) μετρώντας απόσταση 2. Δημιουργούμε λοιπόν το *cluster* {(4, 8), (4, 10)} όπως και στο Παράδειγμα 7.2. Έπειτα η επόμενη μικρότερη απόσταση είναι αυτή των {(4, 8), (4, 10)} και {(6, 8)} με απόσταση $\frac{2+\sqrt{8}}{2}$ οπότε τα συγχωνεύουμε. Στη συνέχεια η απόσταση του (10, 5) από το (11, 4) είναι $\sqrt{2}$ και του (10, 5) από το (12, 3) είναι $\sqrt{8}$ άρα $dist\left(\{(10, 5)\}, \{(11, 4), (12, 3)\}\right) = \frac{\sqrt{2}+\sqrt{8}}{2}$.

Έτσι προκύπτουν τα *clusters*:

- {(10, 5), (11, 4), (12, 3)}
- {(4, 8), (4, 10), (6, 8)}

Συνεχίζουμε με $dist\left((9, 3), \{(10, 5), (11, 4), (12, 3)\}\right) = \sqrt{5}$ οπότε σχηματίζεται καινούργιο *cluster* {(9, 3), (10, 5), (11, 4), (12, 3)}. Τέλος, έχουμε

- $dist\left((5, 2), \{(2, 2), (3, 4)\}\right) = \frac{3+\sqrt{8}}{2} \approx 2.91$
- $dist\left((12, 6), \{(10, 5), (11, 4), (12, 3), (9, 3)\}\right) = \frac{3+\sqrt{5}+\sqrt{5}+\sqrt{18}}{4} \approx 2.92$
- $dist\left((7, 10), \{(4, 8), (4, 10), (6, 8)\}\right) = \frac{3+\sqrt{13}+\sqrt{5}}{3} \approx 2.94$

Με αυτή τη σειρά λοιπόν οδηγούμαστε στα *clusters*

- {(2, 2), (3, 4), (5, 2)}
- {(9, 3), (10, 5), (11, 4), (12, 3), (12, 6)}
- {(4, 8), (4, 10), (6, 8), (7, 10)}

Άσκηση 7.2.3 από το βιβλίο *MMDS*:

α) Το κριτήριο συνένωσης δύο *clusters* είναι να προκύψει η μικρότερη δυνατή ακτίνα. Ως ακτίνα ορίζεται η μέγιστη απόσταση ενός σημείου του *cluster* από το *centroid*.

β) Διάμετρος ενός *cluster* ορίζεται η μεγαλύτερη απόσταση μεταξύ δύο σημείων του *cluster*. Για αρχή, επιλέγουμε να συνενώσουμε τα *clusters* $\{(11, 4)\}$ με $\{(12, 3)\}$ γιατί θα προκύψει η μικρότερη δυνατή διάμετρος ($\sqrt{2}$). Έπειτα ενώνω τις $\{(3, 4)\}$ με $\{(2, 2)\}$, τις $\{(6, 8)\}$ με $\{(7, 10)\}$ και τις $\{(10, 5)\}$ με $\{(12, 6)\}$ όλες με διάμετρο $\sqrt{5}$. Στη συνέχεια τα παρακάτω *clusters* έχουν διάμετρο 3 και θα συγχωνευτούν:


- $\{(4, 10)\}$ με $\{(6, 8), (7, 10)\}$
- $\{(5, 2)\}$ με $\{(3, 4), (2, 2)\}$
- $\{(10, 5), (12, 6)\}$ με $\{(11, 4), (12, 3)\}$

Μένει να συνενώσουμε τα

- $\{(4, 8)\}$ και $\{(4, 10), (6, 8), (7, 10)\}$ με διάμετρο $\sqrt{13}$
- $\{(9, 3)\}$ και $\{(10, 5), (12, 6), (11, 4), (12, 3)\}$ με διάμετρο $\sqrt{18}$

Άσκηση 7.2.5 από το βιβλίο *MMDS*:

Θεωρούμε τα 3 *natural clusters* της παρακάτω εικόνας.



Το *clustroid* για το καθένα, θεωρώντας πως το κριτήριο επιλογής *clustroid* είναι το σημείο με το ελάχιστο άθροισμα αποστάσεων από τα υπόλοιπα σημεία στο *cluster*.

Τα 3 *clusters* είναι:

- *Cluster* 1: $\{(3, 4), (2, 2), (5, 2)\}$
- *Cluster* 2: $\{(4, 10), (7, 10), (4, 8), (6, 8)\}$
- *Cluster* 3: $\{(10, 5), (12, 6), (11, 4), (9, 3), (12, 3)\}$

Τα *clustroids* είναι:

- Το (3, 4) για το *Cluster* 1
- Το (6, 8) για το *Cluster* 2
- Το (11, 4) για το *Cluster* 3

Άσκηση 7.3.2 από το βιβλίο *MMDS*:

Θεώρημα

Έστω κ κλάσεις $C_1, C_2, \dots, C_\kappa$ με την ιδιότητα

$$\max \text{diam}(C_i) < \min_dist(C_i, C_j) \quad \forall i, j \in \{1, \dots, \kappa\}$$

όπου $\min_dist(C_i, C_j)$ (*minimum intercluster distance*) είναι η μικρότερη απόσταση μεταξύ δύο σημείων από δύο διαφορετικές κλάσεις. Τότε ανεξάρτητα από το πρώτο σημείο που επιλέξαμε, αν εφαρμόσουμε τον Αλγόριθμο του 7.3.2 για κ *starting points*, αυτά θα ανήκουν σε διαφορετικές κλάσεις μεταξύ τους.

Αλγόριθμος 7.3.2

Διαλέγουμε τυχαίο σημείο

while πλήθος *starting points* **do**

Πρόσθεσε το σημείο του οποίου η *mindist* από τα επιλεγμένα σημεία είναι όσο το δυνατόν μεγαλύτερη γίνεται

end while

Απόδειξη

Έστω ότι έχουμε επιλέξει $X = \{x_1, \dots, x_s\}$ *starting points* όπου $s < \kappa$ καθένα από τα οποία ανληγεί σε διαφορετική κλάση με βάση τον παραπάνω αλγόριθμο. Καλούμαστε να επιλέξουμε σημείο x_{s+1} . Εφόσον $s < \kappa$ υπάρχει κάποια κλάση που να μην έχει κανένα από τα s σημεία που έχουμε επιλέξει. Άρα αν επιλέξουμε το x_{s+1} από μία καινούργια κλάση και αν επιλέξουμε σημείο y σε οποιαδήποτε από τις υπάρχουσες κλάσεις τότε:

$$\text{dist}(y, X) \leq \max_{1 \leq i \leq \kappa} \text{diam}(C_i) < \min_{1 \leq i, j \leq \kappa, i \neq j} \text{dist}(C_i, C_j) \leq \text{dist}(x_{s+1}, X)$$

Οπότε το σημείο που επιτυγχάνει την μεγιστική απόσταση από το X είναι αναγκαστικά έξω από τις προηγούμενες κλάσεις και έπεται το ζητούμενο.

Άσκηση 7.4.1 από το βιβλίο *MMDS*:

Στον Αλγόριθμο *CURE* τα *representative points* έχουν επιλεγεί έτσι ώστε να βρίσκονται στα όρια των δύο κλάσεων. Ονομάζουμε C_1 την κλάση στο δαχτυλίδι η οποία έχει τα *representative points* της πάνω στον κύκλο ακτίνας o και κέντρου $(0, 0)$ και στον ομόκεντρο κύκλο ακτίνας i . Ονομάζουμε C_2 την κλάση κέντρου $(0, 0)$ και ακτίνας c .

Εφόσον όλα τα *representative points* μετακινήθηκαν κατά 20% εγκύτερα προς τα κεντροειδές τους (αυτό είναι το $(0, 0)$ για όλα), τα εξωτερικά *representative points* της C_1 βρίσκονται πλέον σε κύκλο ακτίνας $0.8 \cdot o$ με κέντρο $(0, 0)$, τα εσωτερικά *representative points* της C_1 σε ακτίνα $0.8 \cdot i$ στον ομόκεντρο κύκλο και αυτά της C_2 απέχουν $0.8 \cdot c$ από το $(0, 0)$.

Σύμφωνα με την εκφώνηση, δύο κλάσεις συγχωνεύονται αν έπειτα από την αναμετάθεση των σημείων τους υπάρχουν *representative points* και από τις δύο κλάσεις απόστασης μικρότερης ή ίσης του d . Μαθηματικά αυτό μεταφράζεται ως:

$$\|x_1 - x_2\|_2 \leq d,$$

όπου x_1 *representative point* της C_1 , x_2 *representative point* της C_2 . Αν επιλέξουμε τα εγκύτερα δυνατά *representative points* των δύο κλάσεων, το

ένα θα βρίσκεται στο *inner circle* της C_1 με απόσταση $0.8 \cdot i$ από το κέντρο και αυτό της C_2 στην ίδια ακτίνα με απόσταση $0.8 \cdot c$ από το κέντρο. Η απόστασή τους είναι

$$(0.8 \cdot i - 0.8 \cdot c) = 0.8(i - c)$$

Τελικά οι κλάσεις C_1 και C_2 δεν πρόκειται να συγχωνευθούν αν

$$d < 0.8(i - c)$$